Machine Learning Project

109550111 吳守元

Github

https://github.com/billwu90325/ML-Final-Project

Model

https://drive.google.com/drive/folders/1bfmlql13XmZxdolGSNjb_fbN4aluY2w-?usp=share_link

Brief introduction

這次的是要用label去預測boolean的output。主要需要處理或考慮的有以下幾個重點

- a. 如何解決含有NaN的row?
- b. 如何處理類別而非數字的column?
- c. 如何在原先的features中提取出更有用的訊息?
- d. 哪種model的表現最好?

Methodology

針對以上幾點,我應對的做法是

- a. 用Kuma_utils的LGBMImputer去impute
- b. 用sklearn的LabelEncoder去把類別轉換成數字
- c. (1) 用原先的data重新組合、計算出新的columns
 - (2) 用sklearn的mutual information score去選擇出幾個與label相關性較強的columns
- d. sklearn的Logistic Regression是表現最好的,而Model的Hyper parameter的部分我是用HW5的方法用kfold的方式找出一組最好的再去fit 整個train

Summary

我覺得這次的project比較麻煩的地方是preprocessing的部分,像是如何填補NaN對data所帶來的影響,不同的方法都會對結果有影響,再者如何把原先的data拼揍、組合出更具有相關性的數據,也是一個需要花時間捉摸的地方。Model的部分我倒是覺得比較沒那麼複雜,主要是kfold比較怎樣的Hyper parameter會有最好的performance。

Comparisons of different approaches

- * Preprocessing
 - a. 直接drop掉有nan的row
 - b. 用LGBMImputer賦值

我一開始是用a的方法,我原本的想法是missing的value不會很多,直接drop掉可以免去其他的過程,但發現處理完只剩一半的train,表現自然不會好。而後來採用的方法是impute,我就選了一個測試出來表換最好的Impute algorithm。


- * Features Engineering
 - a. Missing
 - b. Group avg & std

原本是用這個columns是否missing(boolean)來造出一個新的 column(column個數double),表現有提升但一直沒辦法越過baseline,後來 我就找其他engineering的方法,就找到我目前使用的這個組合,private score就有辦法突破0.59了。

- * Model
 - a. Logistic Regression
 - b. NN(Keras)

原本預期NN的效果會比較好,但後來一直都是regression贏一點點, 我後面就都採用sklearn的logistic regression。

Kaggle score



Reference

- 1. Address "NaN"
 - https://www.kaggle.com/code/sfktrkl/tps-aug-2022/notebook#Modelling
- 2. Feature Engineering:

https://www.kaggle.com/code/themikejones/tps-aug-22-votingclassifier/notebook?scriptVersionId=102761965#4.1-Combine-features-and-create-new

3. Kfold:

https://www.kaggle.com/code/takanashihumbert/tps-aug22-9th-solution